

从已有 CT 学习脑 MRI 样表示： 扩散桥辅助监督精炼的患者级重建研究

摘要

背景与目的： MRI 的及时获取可能受到设备与检查费用、预约和转运流程，以及患者耐受性或特定安全条件的限制。当 CT 已经完成而 MRI 暂时无法获得时，利用已有 CT 学习 MRI 样表示具有研究意义。本研究评估扩散桥辅助监督精炼能否改善配对脑 CT 到合成 MRI 的重建，并检验学习到的中间表示相对于直接 CT 回归的增量价值。

方法： BridgeRefine 首先使用冻结的 SelfRDB 扩散桥生成粗略 MRI，再由约 134 万可训练参数的监督网络联合 CT 与粗略 MRI 进行 L1 精炼。研究包含 180 例配对、共配准脑 CT-MRI 体数据，按患者划分为 144 例训练、18 例验证和 18 例测试，测试集包含 3,415 张轴位切片。比较方法包括 SelfRDB、SynDiff、MG-CycleGAN、BridgeGAN 和直接 CT-only U-Net。实验包括 CT-only、coarse-only 和 CT+coarse 输入消融、三随机种子、患者级配对检验以及效率测量。

结果： 在统一 10 步、2 次递归的重建协议下，BridgeRefine-L1 的患者级 SSIM 为 0.8184 ± 0.0530 ，CT-only 和 coarse-only 分别为 0.8095 ± 0.0536 和 0.7823 ± 0.0538 。BridgeRefine-L1 相比匹配的 CT-only 模型在 17/18 例患者中提高 SSIM，平均配对差为 0.0089，95% bootstrap 置信区间为 [0.0058, 0.0122]，双侧 Wilcoxon 检验 $p = 1.07 \times 10^{-4}$ 。三个随机种子的 BridgeRefine-L1 SSIM 为 0.8184、0.8183 和 0.8147，均值为 0.8171 ± 0.0021 。Gradient loss 在两个共享 seed 上方向不一致。记录的 20 步、5 次递归效率测试显示，BridgeRefine 和 CT-only 的单切片时间分别为 1017 ± 14 ms 和 2.42 ± 0.12 ms。

结论： 结果支持在已有 CT 基础上，通过学习到的中间表示和监督精炼获得小幅重建改善，为 MRI 获取受限背景下的跨模态合成研究提供技术依据。本研究尚未验证费用节省、检查等待缩短或诊断获益；合成图像不能替代真实 MRI，最终采样配置的效率和临床适用性仍需独立验证。

关键词： 合成 MRI；CT 到 MRI 转换；扩散桥；图像到图像转换；患者级评估；医学图像合成

1 引言

需要 MRI 信息并不意味着患者能够及时完成 MRI 检查。设备配置、运行与检查费用可能影响部分医疗环境中的可及性，预约、转运和配套监护流程也可能增加检查等待。对患者而言，难以耐受扫描、无法保持静止或存在特定植入物相关安全条件，可能进一步限制检查实施。植入物是否允许 MRI 需依据具体器械和扫描条件判断，不能将所有金属植入物或起搏器一概视为禁忌。上述因素共同提出一个现实研究问题：当非增强 CT 已经获得，而补充 MRI 暂时不可行时，现有影像数据还能够支持怎样的计算性表征？

利用已有 CT 合成 MRI 样图像，是探索这一问题的一条技术路径。模型从配对数据中学习跨模态结构与外观的统计关系，在推理时仅依赖 CT 生成目标模态样表示。其潜在价值在于充分利用已经采集的数据，为进一步研究跨模态表征和下游任务提供基础。这里的临床需求是研究动机，而非本文已经证明的应用效果：本队列中的患者均有配对 MRI，尚未专门验证 MRI 禁忌、费用受限或长期等待人群。

CT 与 MRI 的成像机制不同,即使完成共配准,二者的强度和局部纹理也不存在简单的一一对应关系。因此,跨模态合成不仅要学习目标图像的外观,还需要评价输出与同一患者实际 MRI 的对应程度 [1]。

患者特异性保真是跨模态合成的关键约束。CT 与 MRI 反映不同的物理属性,某些 MRI 特异性信号未必能由 CT 唯一推断;即使合成图像外观合理,也可能遗漏、扭曲或生成局部特征。因此,本研究不能把“生成得像 MRI”直接解释为“获得了真实 MRI 的诊断信息”。评价必须同时保留配对重建指标、患者级差异和失败边界。

扩散桥连接源端点与靶端点。SelfRDB 将图像到图像扩散桥与递归自一致估计结合,生成粗略 MRI 样表示。但如果最终精炼器同时接收原始 CT,改善可能主要来自直接监督路径,而非扩散桥本身。本文因此以 CT-only 为关键对照,并引入 coarse-only 与联合输入消融,检验桥表示是否改善直接 CT 回归。粗略表示仍来源于 CT,其作用可能是引入学习到的变换或训练先验,而不是增加一次独立的患者测量。

本文将 BridgeRefine 设计为可分离评估的流程。冻结的 SelfRDB bridge 先生成粗略 MRI,轻量监督精炼器再将其与 CT 联合映射到配对 MRI。实验围绕三个问题展开:(1) 监督后桥精炼是否优于 bridge-only 和对抗替代方案;(2) 粗略桥输出是否在 CT 之外提供增量信息;(3) 有限重建收益是否足以抵消推理成本。

本文的贡献包括:在统一患者级协议下比较扩散、对抗和直接监督方法;通过 CT-only、coarse-only 和联合输入消融识别信息来源;使用三随机种子和患者级不确定性分析评估重复性;报告 Gradient 和对抗配置的负结果以及参数量、推理时间和显存,从而明确桥辅助精炼的准确率—效率权衡。

2 相关工作

2.1 配对监督与医学图像合成

医学图像合成涵盖模态间转换、缺失序列补全及图像质量恢复等任务 [1]。Chartsias 等通过模态不变潜在表示开展多模态 MR 合成 [2],展示了共享表示用于目标模态预测的思路。配对监督能够直接约束输出与参考图像的对应关系,但基于像素误差的优化可能倾向于平滑预测。本文使用直接 CT 回归作为关键基线,以判断两阶段方法的收益是否超出直接监督本身。多对比度 MR 合成与 CT 到 MRI 的输入物理属性不同,因此相关工作的结果不与本文数值直接比较。

2.2 对抗图像转换与结构保真

配对与非配对转换依赖不同的监督条件。Isola 等提出的 pix2pix 将条件对抗损失与像素级约束结合,用于具有对应样本的图像转换 [3];Zhu 等提出的 CycleGAN 则通过循环一致性约束学习非配对域之间的映射 [4]。循环一致性并不等同于同一患者目标图像的逐像素监督,因此本文将直接监督模型作为关键对照。配对与非配对转换依赖不同的监督条件。Isola 等提出的 pix2pix 将条件对抗损失与像素级约束结合,用于具有对应样本的图像转换 [3];Zhu 等提出的 CycleGAN 则通过循环一致性约束学习非配对域之间的映射 [4]。后者放宽了训练数据的配对要求,但循环重建约束本身并不提供同一患者真实目标图像的逐像素监督。本文具备配对数据,因此需要将直接监督模型作为关键对照,而不能仅通过优于非配对方法来证明两阶段设计的必要性。

条件生成对抗网络通过学习目标域分布改善合成外观。Dar 等将条件 GAN 用于多对比度 MRI 合成 [5];Khalil 等在脑 CT 到扩散 MRI 转换中引入掩膜引导和保真约束 [6]。与此同时,Cohen 等指出,分布匹配可能生成或删除与疾病有关的特征 [7]。这些研究提示,感知真实感与患

者特异性保真必须区分。本文同时报告 LPIPS 和配对结构指标，并比较对抗精炼与 L1 精炼，分析不同监督目标下的指标权衡。

2.3 扩散模型与桥后精炼

Ho 等提出的去噪扩散概率模型通过学习逆向去噪过程生成图像 [8]。这一范式为扩散式图像建模提供了基础，但标准的噪声到图像生成与本文的 CT 到 MRI 条件映射不是同一任务。对跨模态重建而言，目标不仅是学习 MRI 的总体分布，还包括维持源图像条件与患者结构的对应关系；因此，生成质量的提升不能自动解释为配对重建保真度的提升。

扩散模型通过迭代生成过程建模复杂图像分布，已用于多类医学影像任务，但其计算成本和评价方式仍需结合实际任务分析 [9]。SynDiff 将对抗学习与扩散过程结合用于医学图像转换 [10]，SelfRDB 通过递归自一致估计构建医学图像扩散桥 [11]。本文以冻结桥输出作为中间表示，研究其与原始 CT 联合输入时的重建效果，而不将桥后改善自动归因于扩散过程。

2.4 多维评价与本文定位

Lai 等对 StyleGAN2-ADA 脑 MRI 合成进行多维评价，揭示保真度、多样性和泛化指标可能随训练规模及评价样本量发生不同变化 [12]。其任务是无条件 MRI 生成，本文则属于配对 CT 到 MRI 重建，不能直接沿用其分布评价结论。但两者都强调单个图像指标不足以概括实际效用。本文据此围绕直接回归对照、输入消融、患者级统计和多随机种子开展验证，研究学习到的桥表示是否带来可测的重建增益，并说明现有计算成本记录的适用范围。

3 方法

3.1 研究设计与队列

本回顾性图像转换研究使用 180 例急性脑卒中患者的配对、共配准 CT-MRI 体数据。每例包含非增强 CT、MRI 和与图像空间对齐的二值脑掩膜。患者按 seed 42 划分为 144 例训练、18 例验证和 18 例测试；测试集包含 3,415 张保留轴位切片。患者级划分避免同一患者的切片同时出现在模型开发和测试阶段。

[投稿前补充：研究中心、纳入/排除标准、CT 与 MRI 采集间隔、MRI 序列、扫描仪和场强、CT/MRI 扫描参数、配准软件与质量控制、伦理审批、知情同意、去标识化和数据治理。]

表 1: 患者级数据划分。

划分	患者数	保留切片数	用途
训练	144	27,309	模型拟合
验证	18	3,473	检查点选择
测试	18	3,415	最终评估

3.2 预处理

MRI 进行 N4 偏置场校正。CT 根据直方图峰值自动选择窗宽/窗位：峰值低于 40 使用 35/110，40–60 使用 40/80，高于 60 使用 80/200；MRI 使用第 2 和第 98 百分位窗化。CT 和 MRI 分别使用 CLAHE（裁剪限幅值 1.5、 4×4 网格；裁剪限幅值 2.0、 8×8 网格）及 gamma 校正（0.9

和 1.1)。提取轴位切片，剔除非零像素低于 0.5% 的切片，缩放至 128×128 ，并将强度从 $[0, 255]$ 映射到 $[-1, 1]$ 。

3.3 BridgeRefine 流程

给定 CT 源图像 y 和配对 MRI 靶图像 x_0 ，SelfRDB 桥过程为

$$x_t = \left(1 - \frac{t}{T}\right) x_0 + \frac{t}{T} y + \sqrt{\gamma \frac{t}{T}} \epsilon, \quad (1)$$

其中 $T = 300$ 、 $\gamma = 0.1$ ， ϵ 为高斯噪声。约 1,440 万参数的 bridge 使用直接 x_0 预测和递归估计；所有精炼实验均冻结 bridge，并采用 10 个采样步和两次递归估计。

精炼器接收 CT 与粗略 MRI 的通道拼接：

$$\hat{x}_{\text{MRI}} = R_{\theta}([y, \hat{x}_{\text{bridge}}]). \quad (2)$$

精炼器含卷积编码器、四个残差块、InstanceNorm、双线性上采样和 Tanh 输出，约有 134 万可训练参数。最终模型使用 L1 损失；消融模型额外加入权重为 0.1 的平面内 x/y 梯度损失，不将其解释为显式层间连续性约束。

3.4 输入消融与比较方法

输入消融仅改变精炼器获得的信息：CT-only 只接收 CT，coarse-only 只接收冻结 bridge 输出，CT+coarse 为完整 BridgeRefine。三种配置使用相同患者划分、优化协议、图像尺寸和 seed 42。固定检查点比较包括 SelfRDB、SynDiff、MG-CycleGAN、BridgeGAN、CT-only U-Net 和 BridgeRefine-L1。200 张切片损失筛选、三患者对抗 pilot 和早期条件 DDPM 作为探索性分析，具体数值放入补充材料。

3.5 指标与统计

评价指标包括 SSIM、PSNR、LPIPS、脑掩膜 SSIM/PSNR 和层间 MAD 比值。所有切片级指标先在患者内平均，再在 18 例患者间汇总。主比较为 BridgeRefine-L1 seed 42 与 CT-only seed 42 的配对 SSIM，报告均值差、中位数差、改善患者数、双侧配对 Wilcoxon 检验和 10,000 次百分位 bootstrap 置信区间。与四个生成基线的比较作为独立比较家族，并在该家族内进行 Holm 校正。

3.6 效率测量

效率实验使用 batch size 1，对同一张已加载至 GPU 的 CT 切片先预热调用 10 次，再在每次重复中计时 100 次推理，共重复 3 次。计时前后进行 CUDA 同步，不包含模型加载与输入传输时间。记录的 BridgeRefine 基准采用 20 个采样步和 5 次递归，不代表主重建表所用的 10 步、2 次递归配置。显存是进程级峰值分配；测量 BridgeRefine 时 CT-only 模型仍驻留显存，不能解释为独立模型显存或额外激活显存。

4 结果

4.1 固定检查点比较

BridgeRefine-L1 在 SSIM、PSNR、脑掩膜指标和 MAD 比值方面取得最佳或最接近目标的结果：SSIM 为 0.8184 ± 0.0530 ，PSNR 为 19.95 dB，LPIPS 为 0.125，掩膜 SSIM 为 0.8562，MAD 比值为 0.967。SelfRDB bridge-only 的 SSIM 为 0.5855，说明监督精炼产生了最大的观测增益。BridgeGAN 和 MG-CycleGAN 的 LPIPS 更低，说明感知纹理指标与配对结构指标并不总是给出相同排序。

表 2: 固定检查点结果。SSIM 标准差为患者间样本标准差。PSNR 单位为 dB。

方法	SSIM	PSNR	LPIPS	掩膜 SSIM	MAD 比值
SelfRDB	0.5855 ± 0.0395	16.44	0.229	0.7545	3.608
SynDiff	0.7473 ± 0.0687	18.36	0.121	0.8207	1.575
MG-CycleGAN	0.7882 ± 0.0533	18.86	0.082	0.8403	1.202
BridgeGAN	0.8046 ± 0.0538	18.92	0.078	0.8462	1.409
CT-only	0.8095 ± 0.0536	19.77	0.129	0.8528	0.853
BridgeRefine-L1	0.8184 ± 0.0530	19.95	0.125	0.8562	0.967

4.2 输入来源消融

CT-only、coarse-only 和 CT+coarse 的 SSIM 分别为 0.8095 ± 0.0536 、 0.7823 ± 0.0538 和 0.8184 ± 0.0530 。因此，CT 是主要信息来源；粗略 MRI 单独使用不足以替代 CT，但加入 CT 后带来有限的额外收益。由于该消融使用单一 seed，结果用于支持组件作用解释，不作为完整方差分析。

4.3 患者级配对和随机种子

BridgeRefine-L1 相比匹配 CT-only seed 42 在 17/18 例患者中提高 SSIM，平均配对差为 0.0089，中位差为 0.0088，95% bootstrap CI 为 [0.0058, 0.0122]，双侧 Wilcoxon 原始 $p = 1.07 \times 10^{-4}$ 。BridgeRefine-L1 三个 seed 的结果为 0.8184、0.8183 和 0.8147，均值为 0.8171 ± 0.0021 ；CT-only 三个 seed 为 0.8095、0.8050 和 0.7883，均值为 0.8009 ± 0.0112 。两组仅有三次运行，标准差用于描述性比较。

表 3: 三次训练运行的队列 SSIM。运行间标准差统一采用样本标准差。

方法	seed 42	seed 123	seed 2026	均值与运行 SD
CT-only	0.8095	0.8050	0.7883	0.8009 ± 0.0112
BridgeRefine-L1	0.8184	0.8183	0.8147	0.8171 ± 0.0021

4.4 损失与对抗结果

L1+Gradient 在探索性子集上曾占优，但完整队列的两个共享 seed 方向不一致，因此不支持将 Gradient loss 作为核心贡献。BridgeGAN 在完整队列中的 SSIM 为 0.8046，低于 BridgeRefine-L1 的 0.8184；该结论仅适用于所测试的损失和训练配置。

4.5 效率结果

在记录的 20 步、5 次递归配置下，CT-only 推理时间为 2.42 ± 0.12 ms/slice，BridgeRefine 为 1017 ± 14 ms/slice。时间比约 420 倍。该结果说明 bridge 采样会带来显著延迟，但由于主重建采用 10 步、2 次递归，最终配置的延迟仍需单独测量。

5 讨论

5.1 面向 MRI 获取受限场景的研究意义

本研究的应用出发点是 MRI 信息需求与检查可及性之间的差距。联合输入在 17/18 名测试患者中改善 SSIM，说明学习到的桥表示在当前配对队列上具有可测的重建价值。这一发现为利用已有 CT 开展跨模态合成研究提供依据，但其绝对提升较小，尚不足以确定合成图像是否有助于病灶识别或临床决策。下一步应围绕明确的下游任务验证，而非仅依靠图像外观扩大应用结论。

费用、时间和患者安全是不同的验证维度。本研究未测量检查费用、完整诊疗成本、预约等待、转运耗时或治疗延迟，因此不能宣称降低医疗费用或缩短救治时间。MRI 不使用电离辐射，省去 MRI 检查不能被解释为减少辐射暴露。原始计时实验只反映特定采样配置的计算开销，且未包含完整预处理和临床流程，不能直接与 MRI 扫描时间作等效比较。即便后续证明生成速度足够快，仍需单独评价临床收益与错误风险。

5.2 输入表示与重建证据

本研究的核心发现是，监督精炼产生最大性能变化，CT 是主要信息源，粗略 MRI 作为学习到的中间表示提供较小增益。由于粗略 MRI 本身由 CT 生成，输入消融不能证明它恢复了 CT 中不存在的独立 MRI 信息；更谨慎的解释是，bridge 输出提供了有用的学习表示或训练先验。

该结果也说明评价指标具有维度依赖性。BridgeRefine-L1 在 SSIM、PSNR、脑掩膜指标和 MAD 比值上表现最好，而 BridgeGAN 与 MG-CycleGAN 的 LPIPS 更低。因此，医学图像合成不能只用单一指标概括。SSIM、PSNR、LPIPS、掩膜指标和 MAD 比值均属于重建评价，不能替代病灶敏感度、诊断特异度、读者判断或下游任务。

Gradient loss 未显示一致的独立收益，说明探索性子集结果不能替代完整患者级验证。对抗配置在当前实验中未改善 SSIM，但不同判别器、损失权重和训练日程可能产生不同结果。本文仅报告所测试设置的经验结果。

BridgeRefine 的准确率提升伴随较高推理成本。当前效率结果对应 20 步、5 次递归配置，不能直接用于宣称 10 步、2 次递归配置的延迟。未来可评估步数减少、蒸馏或缓存中间表示，但这些方案需要单独验证。

5.3 局限性与后续验证

本研究为单中心 180 例队列，独立测试单位仅 18 例患者；模型使用 128×128 二维轴位切片，未显式建模三维一致性；输入消融只有一个 seed，多 seed 仅有三次运行；Gradient 和对抗 pilot 不是确认性患者级证据；缺乏外部队列、盲法读片、病灶终点和下游任务；CT-only 其他 seed 的完整非 SSIM 指标尚未全部重新计算；部分旧 checkpoint 没有完整逐 epoch 日志。上述限制将结论限定为本队列上的重建保真度。

6 结论

面向 MRI 暂时难以获得这一现实需求, BridgeRefine 探索了从已有 CT 学习 MRI 样表示的两阶段重建流程。联合输入相对直接 CT 回归的平均 SSIM 提升为 0.0089, 17/18 名测试患者改善, 支持学习到的中间表示在本队列上的有限增量价值。该结果属于早期技术验证, 尚不能推出降低检查成本、缩短临床等待或替代 MRI 的结论。未来应在外部数据和明确病灶任务上评价保真性与错误风险, 并测量最终配置的计算效率及实际流程成本。

声明

伦理审批: [投稿前补充: 补充伦理审批或豁免信息。]

知情同意: [投稿前补充: 补充知情同意或豁免信息。]

数据和代码可用性: [投稿前补充: 补充符合数据治理要求的访问和代码公开说明。]

基金、利益冲突和作者贡献: [投稿前补充: 补充真实信息。]

参考文献

- [1] Dayarathna S, et al. Deep learning based synthesis of MRI, CT and PET: Review and analysis. *Medical Image Analysis*, 2024, 92:103046. doi:10.1016/j.media.2023.103046.
- [2] Chatsias A, et al. Multimodal MR Synthesis via Modality-Invariant Latent Representation. *IEEE Transactions on Medical Imaging*, 2018, 37(3):803–814. doi:10.1109/TMI.2017.2764326.
- [3] Isola P, Zhu JY, Zhou T, Efros AA. Image-to-Image Translation with Conditional Adversarial Networks. *CVPR*, 2017:1125–1134.
- [4] Zhu JY, Park T, Isola P, Efros AA. Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks. *ICCV*, 2017:2223–2232.
- [5] Dar SUH, et al. Image Synthesis in Multi-Contrast MRI With Conditional Generative Adversarial Networks. *IEEE Transactions on Medical Imaging*, 2019, 38(10):2375–2388. doi:10.1109/TMI.2019.2901750.
- [6] Khalil MA, et al. Mask-Guided and Fidelity-Constrained Deep Learning Model for Accurate Translation of Brain CT Images to Diffusion MRI Images in Acute Stroke Patients. *Journal of Imaging Informatics in Medicine*, 2025. doi:10.1007/s10278-025-01649-6.
- [7] Cohen JP, Luck M, Honari S. Distribution Matching Losses Can Hallucinate Features in Medical Image Translation. *MICCAI 2018*:529–536. doi:10.1007/978-3-030-00928-1_60.
- [8] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models. *NeurIPS*, 2020, 33:6840–6851.
- [9] Kazerooni A, et al. Diffusion models in medical imaging: A comprehensive survey. *Medical Image Analysis*, 2023, 88:102846. doi:10.1016/j.media.2023.102846.

- [10] Özbey M, et al. Unsupervised Medical Image Translation with Adversarial Diffusion Models. *IEEE Transactions on Medical Imaging*, 2023, 42(12):3524–3539. doi:10.1109/TMI.2023.3290149.
- [11] Arslan F, et al. Self-Consistent Recursive Diffusion Bridge for Medical Image Translation. *Medical Image Analysis*, 2025, 106:103747. doi:10.1016/j.media.2025.103747.
- [12] Lai M, et al. Generating Brain MRI with StyleGAN2-ADA: The Effect of the Training Set Size on the Quality of Synthetic Images. *Journal of Imaging Informatics in Medicine*, 2026, 39:2319–2329. doi:10.1007/s10278-025-01536-0.