

# 扩散桥辅助的脑 CT 到 MRI 合成：患者级保真度与效率评估

## 摘要

**背景与目的：** MRI 的及时获取可能受到设备与检查费用、预约和转运流程，以及患者耐受性或特定安全条件的限制。当 CT 已经完成而 MRI 暂时无法获得时，利用已有 CT 学习 MRI 样表示具有研究意义。本研究评估扩散桥辅助监督精炼能否改善配对脑 CT 到合成 MRI 的重建，并检验学习到的中间表示相对于直接 CT 回归的增量价值。

**方法：** BridgeRefine 首先使用冻结的 SelfRDB 扩散桥生成粗略 MRI，再由约 134 万可训练参数的监督网络联合 CT 与粗略 MRI 进行 L1 精炼。研究包含 180 例配对、共配准脑 CT-MRI 体数据，按患者划分为 144 例训练、18 例验证和 18 例测试，测试集包含 3,415 张轴位切片。比较方法包括 SelfRDB、SynDiff、MG-CycleGAN、BridgeGAN 和直接 CT-only U-Net。实验包括 CT-only、coarse-only 和 CT+coarse 输入消融、三随机种子、患者级配对检验以及效率测量。

**结果：** 在统一 10 步、2 次递归的重建协议下，BridgeRefine-L1 的患者级 SSIM 为  $0.8184 \pm 0.0530$ ，CT-only 和 coarse-only 分别为  $0.8095 \pm 0.0536$  和  $0.7823 \pm 0.0538$ 。BridgeRefine-L1 相比匹配的 CT-only 模型在 17/18 例患者中提高 SSIM，平均配对差为 0.0089，95% bootstrap 置信区间为 [0.0058, 0.0122]，双侧 Wilcoxon 原始  $p = 1.07 \times 10^{-4}$ ，在预先定义的六项比较家族中 Holm 校正后  $p = 2.14 \times 10^{-4}$ 。三个随机种子的 BridgeRefine-L1 SSIM 为 0.8184、0.8183 和 0.8147，均值为  $0.8171 \pm 0.0021$ 。Gradient loss 在两个共享 seed 上方向不一致。在独立的 10 步、2 次递归效率测试中，BridgeRefine 和 CT-only 的单切片时间分别为  $233.6 \pm 12.6$  ms 和  $2.06 \pm 0.18$  ms；对应额外推理显存为 134.0 MB 和 39.3 MB。

**结论：** 结果支持在已有 CT 基础上，通过学习到的中间表示和监督精炼获得小幅重建改善，但该收益伴随约 113 倍的记录推理时间比和更高额外推理显存。本研究尚未验证费用节省、检查等待缩短或诊断获益；合成图像不能替代真实 MRI。

**关键词：** 合成 MRI；CT 到 MRI 转换；扩散桥；图像到图像转换；患者级评估；医学图像合成

## 1 引言

MRI 在软组织对比和多参数信息方面具有优势，但设备可及性、检查流程、患者耐受性及特定安全条件可能限制其及时获取。当非增强 CT 已经完成而补充 MRI 暂时不可行时，从已有 CT 学习 MRI 样表示成为值得研究的计算问题。本文将这一临床背景作为研究动机，而非已验证的应用场景：当前队列中的患者均具有配对 MRI，研究目标是评估配对 CT-MRI 重建的技术可行性及其患者级保真度，而不是证明合成图像能够替代真实 MRI。

CT 与 MRI 的成像机制和强度编码不同，即使完成共配准，二者之间也不存在确定的一一映射；部分 MRI 特异性信号无法由 CT 唯一推断。因此，模型必须同时处理目标模态外观建模和源-靶患者对应关系保持两个目标。配对监督方法能够直接利用参考 MRI 约束输出，但像素回归在不确定区域可能产生平滑预测；条件或非配对对抗方法可以改善目标域外观，却可能通过生成或删除局部特征获得感知真实感 [1, 3, 7]。由此，“生成得像 MRI”不能直接等同于“保留了真实 MRI 的诊断信息”，评价需要结合配对重建指标、脑掩膜结构指标、感知指标和患者级统计。

扩散模型通过迭代去噪建模复杂分布，扩散桥进一步提供从源端到靶端点的条件中间表示 [8, 9, 11]。然而，SelfRDB 产生的粗略 MRI 仍然由 CT 推断，并不是独立的患者测量；当精炼器同时接收 CT 和粗略 MRI 时，性能变化也可能来自直接监督路径或输入表示变化，而非扩散桥本身。因此，本文不把桥输出解释为新增 MRI 信息，而是提出一个可分离评估流程：冻结 SelfRDB 生成粗略表示，再由轻量监督精炼器将其与 CT 联合映射到配对 MRI，并以 CT-only 和 coarse-only 配置检验其中间表示的增量作用。

围绕上述问题，本文在统一患者级协议下比较扩散、对抗和直接监督方法，报告 SSIM、PSNR、LPIPS、脑掩膜指标和层间一致性，并结合三随机种子、配对统计和独立 10 步  $\times 2$  递归效率测量回答三个问题：监督精炼是否优于现有比较方法，粗略桥表示是否在 CT 之外提供可测增量，以及该增量是否值得其计算代价。本文的贡献是对桥辅助中间表示进行透明的组件归因和准确率-效率评估；Gradient 和对抗配置的负结果也被保留，以限定结论适用范围。

## 2 相关工作

### 2.1 配对监督与医学图像合成

医学图像合成涵盖模态间转换、缺失序列补全及图像质量恢复等任务 [1]。Chartsias 等通过模态不变潜在表示开展多模态 MR 合成 [2]，展示了共享表示用于目标模态预测的思路。配对监督能够直接约束输出与参考图像的对应关系，但基于像素误差的优化可能倾向于平滑预测。本文使用直接 CT 回归作为关键基线，以判断两阶段方法的收益是否超出直接监督本身。多对比度 MR 合成与 CT 到 MRI 的输入物理属性不同，因此相关工作的结果不与本文数值直接比较。

### 2.2 对抗图像转换与结构保真

配对与非配对转换依赖不同的监督条件。Isola 等提出的 pix2pix 将条件对抗损失与像素级约束结合，用于具有对应样本的图像转换 [3]；Zhu 等提出的 CycleGAN 则通过循环一致性约束学习非配对域之间的映射 [4]。后者放宽了训练数据的配对要求，但循环重建约束本身并不提供同一患者真实目标图像的逐像素监督。本文具备配对数据，因此需要将直接监督模型作为关键对照，而不能仅通过优于非配对方法来证明两阶段设计的必要性。

条件生成对抗网络通过学习目标域分布改善合成外观。Dar 等将条件 GAN 用于多对比度 MRI 合成 [5]；Khalil 等在脑 CT 到扩散 MRI 转换中引入掩膜引导和保真约束 [6]。与此同时，Cohen 等指出，分布匹配可能生成或删除与疾病有关的特征 [7]。这些研究提示，感知真实感与患者特异性保真必须区分。本文同时报告 LPIPS 和配对结构指标，并比较对抗精炼与 L1 精炼，分析不同监督目标下的指标权衡。

### 2.3 扩散模型与桥后精炼

Ho 等提出的去噪扩散概率模型通过学习逆向去噪过程生成图像 [8]。这一范式为扩散式图像建模提供了基础，但标准的噪声到图像生成与本文的 CT 到 MRI 条件映射不是同一任务。对跨模态重建而言，目标不仅是学习 MRI 的总体分布，还包括维持源图像条件与患者结构的对应关系；因此，生成质量的提升不能自动解释为配对重建保真度的提升。

扩散模型通过迭代生成过程建模复杂图像分布，已用于多类医学影像任务，但其计算成本和评价方式仍需结合实际任务分析 [9]。SynDiff 将对抗学习与扩散过程结合用于医学图像转换 [10]，

SelfRDB 通过递归自一致估计构建医学图像扩散桥 [11]。本文以冻结桥输出作为中间表示，研究其与原始 CT 联合输入时的重建效果，而不将桥后改善自动归因于扩散过程。

## 2.4 多维评价与本文定位

Lai 等对 StyleGAN2-ADA 脑 MRI 合成进行多维评价，揭示保真度、多样性和泛化指标可能随训练规模及评价样本量发生不同变化 [12]。其任务是无条件 MRI 生成，本文则属于配对 CT 到 MRI 重建，不能直接沿用其分布评价结论。但两者都强调单个图像指标不足以概括实际效用。本文据此围绕直接回归对照、输入消融、患者级统计和多随机种子开展验证，研究学习到的桥表示是否带来可测的重建增益，并说明现有计算成本记录的适用范围。

# 3 方法

## 3.1 研究设计与队列

本回顾性图像转换研究使用 180 例急性脑卒中患者的配对、共配准 CT-MRI 体数据。每例包含非增强 CT、MRI 和与图像空间对齐的二值脑掩膜。患者按 seed 42 划分为 144 例训练、18 例验证和 18 例测试；测试集包含 3,415 张保留轴位切片。患者级划分避免同一患者的切片同时出现在模型开发和测试阶段。

[投稿前补充：研究中心、纳入/排除标准、CT 与 MRI 采集间隔、MRI 序列、扫描仪和场强、CT/MRI 扫描参数、配准软件与质量控制、伦理审批、知情同意、去标识化和数据治理。]

表 1: 患者级数据划分。

| 划分 | 患者数 | 保留切片数  | 用途    |
|----|-----|--------|-------|
| 训练 | 144 | 27,309 | 模型拟合  |
| 验证 | 18  | 3,473  | 检查点选择 |
| 测试 | 18  | 3,415  | 最终评估  |

## 3.2 预处理

MRI 进行 N4 偏置场校正。CT 根据直方图峰值自动选择窗宽/窗位：峰值低于 40 使用 35/110，40–60 使用 40/80，高于 60 使用 80/200；MRI 使用第 2 和第 98 百分位窗化。CT 和 MRI 分别使用 CLAHE（裁剪限幅值 1.5、 $4 \times 4$  网格；裁剪限幅值 2.0、 $8 \times 8$  网格）及 gamma 校正（0.9 和 1.1）。提取轴位切片，剔除非零像素低于 0.5% 的切片，缩放至  $128 \times 128$ ，并将强度从  $[0, 255]$  映射到  $[-1, 1]$ 。

## 3.3 BridgeRefine 流程

给定 CT 源图像  $y$  和配对 MRI 靶图像  $x_0$ ，SelfRDB 桥过程为

$$x_t = \left(1 - \frac{t}{T}\right)x_0 + \frac{t}{T}y + \sqrt{\gamma \frac{t}{T}}\epsilon, \quad (1)$$

其中  $T = 300$ 、 $\gamma = 0.1$ ， $\epsilon$  为高斯噪声。约 1,440 万参数的 bridge 使用直接  $x_0$  预测和递归估计；所有精炼实验均冻结 bridge，并采用 10 个采样步和两次递归估计。


**BridgeRefine Two-Stage Framework for Paired Brain CT-to-MRI Synthesis**

图 1: BridgeRefine 两阶段流程。上方为推理路径：输入 CT 经冻结 SelfRDB 扩散桥得到粗略 MRI，再与 CT 在通道维拼接后输入可训练精炼器；下方展开冻结桥、监督精炼器及训练阶段的 L1 监督。图中的 CT 和扩散采样中间态为流程示意占位，不用于定性结果或性能判断。

精炼器接收 CT 与粗略 MRI 的通道拼接：

$$\hat{x}_{\text{MRI}} = R_{\theta}([y, \hat{x}_{\text{bridge}}]). \quad (2)$$

精炼器含卷积编码器、四个残差块、InstanceNorm、双线性上采样和 Tanh 输出，约有 134 万可训练参数。最终模型使用 L1 损失；消融模型额外加入权重为 0.1 的平面内 x/y 梯度损失，不将其解释为显式层间连续性约束。

### 3.4 输入消融与比较方法

输入消融仅改变精炼器获得的信息：CT-only 只接收 CT，coarse-only 只接收冻结 bridge 输出，CT+coarse 为完整 BridgeRefine。三种配置使用相同患者划分、优化协议、图像尺寸和 seed 42。固定检查点比较包括 SelfRDB、SynDiff、MG-CycleGAN、BridgeGAN、CT-only U-Net 和 BridgeRefine-L1。200 张切片损失筛选、三患者对抗 pilot 和早期条件 DDPM 作为探索性分析，具体数值放入补充材料。

### 3.5 指标与统计

评价指标包括 SSIM、PSNR、LPIPS、脑掩膜 SSIM/PSNR 和层间 MAD 比值。所有切片级指标先在患者内平均，再在 18 例患者间汇总。主比较为 BridgeRefine-L1 seed 42 与 CT-only seed 42 的配对 SSIM，报告均值差、中位数差、改善患者数、双侧配对 Wilcoxon 检验和 10,000 次百分位 bootstrap 置信区间。预先定义的比较家族包含 BridgeRefine-L1 分别对 SelfRDB、SynDiff、MG-CycleGAN、BridgeGAN、coarse-only 和 CT-only 的六项患者级 SSIM 比较，并在同一比较家族内进行 Holm 校正；校正只用于控制该家族的多重比较，不改变效应量解释。

### 3.6 效率测量

效率实验使用 batch size 1，在两个独立进程中分别测量 CT-only 和 BridgeRefine。每次先预热 20 张切片，再正式计时 100 张切片，共重复 3 次；计时前后进行 CUDA 同步，不包含模型加载、输入传输和预处理。BridgeRefine 使用主实验的 10 个采样步和 2 次递归估计。显存定义为模型与输入分配后记录的额外推理峰值，两个模型不共驻显存。

## 4 结果

### 4.1 固定检查点比较




图 2: 固定检查点的患者级主要结果。不同指标从配对保真、感知相似度和脑掩膜结构等维度刻画模型表现。

BridgeRefine-L1 在 SSIM、PSNR 和脑掩膜指标上取得最高值：SSIM 为  $0.8184 \pm 0.0530$ ，PSNR 为 19.95 dB，LPIPS 为 0.125，掩膜 SSIM 为 0.8562；MAD 比值为 0.967，接近 1 的理想参考但不优于 CT-only 的 0.853。SelfRDB bridge-only 的 SSIM 为 0.5855，说明监督精炼产生了最大的观测增益。BridgeGAN 和 MG-CycleGAN 的 LPIPS 更低，说明感知纹理指标与配对结构指标并不总是给出相同排序。

### 4.2 输入来源消融

CT-only、coarse-only 和 CT+coarse 的 SSIM 分别为  $0.8095 \pm 0.0536$ 、 $0.7823 \pm 0.0538$  和  $0.8184 \pm 0.0530$ 。因此，CT 是主要信息来源；粗略 MRI 单独使用不足以替代 CT，但加入 CT 后带来有限的额外收益。由于该消融使用单一 seed，结果用于支持组件作用解释，不作为完整方差分析。

表 2: 固定检查点结果。SSIM 标准差为患者间样本标准差。PSNR 单位为 dB。

| 方法              | SSIM                | PSNR  | LPIPS | 掩膜 SSIM | MAD 比值 |
|-----------------|---------------------|-------|-------|---------|--------|
| SelfRDB         | $0.5855 \pm 0.0395$ | 16.44 | 0.229 | 0.7545  | 3.608  |
| SynDiff         | $0.7473 \pm 0.0687$ | 18.36 | 0.121 | 0.8207  | 1.575  |
| MG-CycleGAN     | $0.7882 \pm 0.0533$ | 18.86 | 0.082 | 0.8403  | 1.202  |
| BridgeGAN       | $0.8046 \pm 0.0538$ | 18.92 | 0.078 | 0.8462  | 1.409  |
| CT-only         | $0.8095 \pm 0.0536$ | 19.77 | 0.129 | 0.8528  | 0.853  |
| BridgeRefine-L1 | $0.8184 \pm 0.0530$ | 19.95 | 0.125 | 0.8562  | 0.967  |

#### 4.3 患者级配对和随机种子




图 3: 三个测试患者代表性切片的定性对比。列依次为 CT、真实 MRI、coarse MRI、BridgeRefine-L1、CT-only 和误差图；病例按 BridgeRefine-L1 seed-42 患者级 SSIM 选择为高、中位和低表现。各模型使用同一显示范围，误差图由原始数组计算；该图用于补充而非替代患者级定量评价。

BridgeRefine-L1 相比匹配 CT-only seed 42 在 17/18 例患者中提高 SSIM，平均配对差为 0.0089，中位差为 0.0088，95% bootstrap CI 为 [0.0058, 0.0122]，双侧 Wilcoxon 原始  $p = 1.07 \times 10^{-4}$ 。BridgeRefine-L1 三个 seed 的结果为 0.8184、0.8183 和 0.8147，均值为  $0.8171 \pm 0.0021$ ；CT-only 三个 seed 为 0.8095、0.8050 和 0.7883，均值为  $0.8009 \pm 0.0112$ 。两组仅有三次运行，标准差用于描述性比较。

表 3: 三次训练运行的队列 SSIM。运行间标准差统一采用样本标准差。

| 方法              | seed 42 | seed 123 | seed 2026 | 均值与运行 SD            |
|-----------------|---------|----------|-----------|---------------------|
| CT-only         | 0.8095  | 0.8050   | 0.7883    | $0.8009 \pm 0.0112$ |
| BridgeRefine-L1 | 0.8184  | 0.8183   | 0.8147    | $0.8171 \pm 0.0021$ |

#### 4.4 损失与对抗结果

L1+Gradient 在探索性子集上曾占优，但完整队列的两个共享 seed 方向不一致，因此不支持将 Gradient loss 作为核心贡献。BridgeGAN 在完整队列中的 SSIM 为 0.8046，低于 BridgeRefine-L1 的 0.8184；该结论仅适用于所测试的损失和训练配置。

## 4.5 效率结果




图 4: 统一 10 步、2 次递归协议下的独立效率测量。CT-only 与 BridgeRefine 在分进程中分别测量；时间不包含模型加载、输入传输和预处理，显存表示模型与输入分配后的额外推理峰值。

在独立的 10 步、2 次递归配置下，CT-only 推理时间为  $2.06 \pm 0.18$  ms/slice，BridgeRefine 为  $233.6 \pm 12.6$  ms/slice，时间比约 113 倍。对应额外推理显存 allocated 分别为 39.3 MB 和 134.0 MB；两种模型分进程独立测量，不包含模型加载、输入传输和预处理。该结果显示桥采样带来显著计算代价，且时间与显存不能直接外推为临床流程成本。

## 5 讨论

### 5.1 面向 MRI 获取受限场景的研究意义

本研究的应用出发点是 MRI 信息需求与检查可及性之间的差距。联合输入在 17/18 名测试患者中改善 SSIM，说明学习到的桥表示在当前配对队列上具有可测的重建价值。这一发现为利用已有 CT 开展跨模态合成研究提供依据，但其绝对提升较小，尚不足以确定合成图像是否有助于病灶识别或临床决策。下一步应围绕明确的下游任务验证，而非仅依靠图像外观扩大应用结论。

费用、时间和患者安全是不同的验证维度。本研究未测量检查费用、完整诊疗成本、预约等待、转运耗时或治疗延迟，因此不能宣称降低医疗费用或缩短救治时间。MRI 不使用电离辐射，省去 MRI 检查不能被解释为减少辐射暴露。原始计时实验只反映特定采样配置的计算开销，且未包含完整预处理和临床流程，不能直接与 MRI 扫描时间作等效比较。即便后续证明生成速度足够快，仍需单独评价临床收益与错误风险。

### 5.2 输入表示与重建证据

本研究的核心发现是，监督精炼产生最大性能变化，CT 是主要信息源，粗略 MRI 作为学习到的中间表示提供较小增益。由于粗略 MRI 本身由 CT 生成，输入消融不能证明它恢复了 CT 中不存在的独立 MRI 信息；更谨慎的解释是，bridge 输出提供了有用的学习表示或训练先验。

该结果也说明评价指标具有维度依赖性。BridgeRefine-L1 在 SSIM、PSNR 和脑掩膜指标上表现最好，但 MAD ratio 并不优于 CT-only，而 BridgeGAN 与 MG-CycleGAN 的 LPIPS 更低。因此，医学图像合成不能只用单一指标概括。SSIM、PSNR、LPIPS、掩膜指标和 MAD 比值均属于重建评价，不能替代病灶敏感度、诊断特异度、读者判断或下游任务。

Gradient loss 未显示一致的独立收益，说明探索性子集结果不能替代完整患者级验证。对抗

配置在当前实验中未改善 SSIM，但不同判别器、损失权重和训练日程可能产生不同结果。本文仅报告所测试设置的经验结果。

BridgeRefine 的准确率提升伴随较高推理成本。独立 10 步、2 次递归测量显示其单切片时间约为 CT-only 的 113 倍，额外推理显存也更高。该结果仅反映 batch size 1、固定 GPU 和不含数据传输的基准协议，不能直接等同于临床流程时间或经济成本。未来可评估步数减少、蒸馏或缓存中间表示，但这些方案需要单独验证。

### 5.3 局限性与后续验证

本研究为单中心 180 例队列，独立测试单位仅 18 例患者；模型使用  $128 \times 128$  二维轴位切片，未显式建模三维一致性；输入消融以 seed 42 为主，多 seed 仅有三次运行；Gradient 和对抗 pilot 不是确认性患者级证据；缺乏外部队列、盲法读片、病灶终点和下游任务；CT-only 其他 seed 的完整非 SSIM 指标尚未形成与 seed 42 同等粒度的逐患者导出；部分旧 checkpoint 没有完整逐 epoch 日志。上述限制将结论限定为本队列上的重建保真度。

## 6 结论

面向 MRI 暂时难以获得这一现实需求，BridgeRefine 评估了从已有 CT 学习 MRI 样表示的两阶段重建流程。联合输入相对直接 CT 回归的平均患者级 SSIM 提升为 0.0089，17/18 名测试患者改善；在统一 10 步、2 次递归协议下，该收益伴随约 113 倍的记录推理时间和更高额外推理显存。因此，本文的结论是桥辅助精炼在本队列上提供了有限但可测的重建增量，同时存在明显效率代价，而不是已经证明 MRI 替代或临床获益。未来应在外部数据和明确病灶任务上评价保真性与错误风险，并测量完整流程成本。

## 声明

**伦理审批：** [投稿前补充：补充伦理审批或豁免信息。]

**知情同意：** [投稿前补充：补充知情同意或豁免信息。]

**数据和代码可用性：** [投稿前补充：补充符合数据治理要求的访问和代码公开说明。]

**基金、利益冲突和作者贡献：** [投稿前补充：补充真实信息。]

## 参考文献

- [1] Dayarathna S, et al. Deep learning based synthesis of MRI, CT and PET: Review and analysis. *Medical Image Analysis*, 2024, 92:103046. doi:10.1016/j.media.2023.103046.
- [2] Chartsias A, et al. Multimodal MR Synthesis via Modality-Invariant Latent Representation. *IEEE Transactions on Medical Imaging*, 2018, 37(3):803–814. doi:10.1109/TMI.2017.2764326.
- [3] Isola P, Zhu JY, Zhou T, Efros AA. Image-to-Image Translation with Conditional Adversarial Networks. *CVPR*, 2017:1125–1134.
- [4] Zhu JY, Park T, Isola P, Efros AA. Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks. *ICCV*, 2017:2223–2232.

- [5] Dar SUH, et al. Image Synthesis in Multi-Contrast MRI With Conditional Generative Adversarial Networks. *IEEE Transactions on Medical Imaging*, 2019, 38(10):2375–2388. doi:10.1109/TMI.2019.2901750.
- [6] Khalil MA, et al. Mask-Guided and Fidelity-Constrained Deep Learning Model for Accurate Translation of Brain CT Images to Diffusion MRI Images in Acute Stroke Patients. *Journal of Imaging Informatics in Medicine*, 2025. doi:10.1007/s10278-025-01649-6.
- [7] Cohen JP, Luck M, Honari S. Distribution Matching Losses Can Hallucinate Features in Medical Image Translation. *MICCAI 2018*:529–536. doi:10.1007/978-3-030-00928-1\_60.
- [8] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models. *NeurIPS*, 2020, 33:6840–6851.
- [9] Kazerooni A, et al. Diffusion models in medical imaging: A comprehensive survey. *Medical Image Analysis*, 2023, 88:102846. doi:10.1016/j.media.2023.102846.
- [10] Özbey M, et al. Unsupervised Medical Image Translation with Adversarial Diffusion Models. *IEEE Transactions on Medical Imaging*, 2023, 42(12):3524–3539. doi:10.1109/TMI.2023.3290149.
- [11] Arslan F, et al. Self-Consistent Recursive Diffusion Bridge for Medical Image Translation. *Medical Image Analysis*, 2025, 106:103747. doi:10.1016/j.media.2025.103747.
- [12] Lai M, et al. Generating Brain MRI with StyleGAN2-ADA: The Effect of the Training Set Size on the Quality of Synthetic Images. *Journal of Imaging Informatics in Medicine*, 2026, 39:2319–2329. doi:10.1007/s10278-025-01536-0.